

Введение в АД

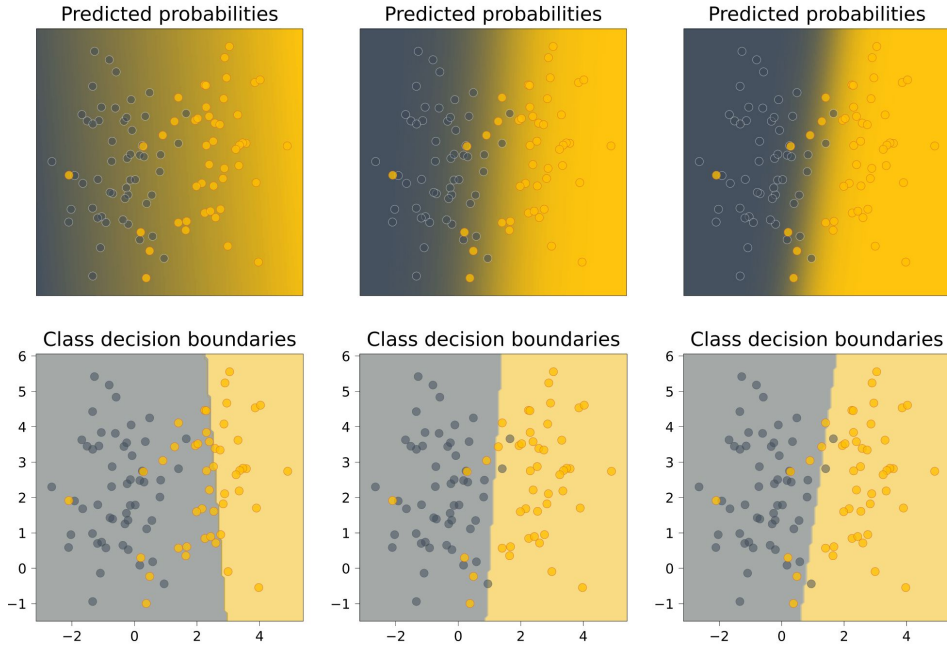
Лекция 4

SVM, PCA, SVD



На подумать



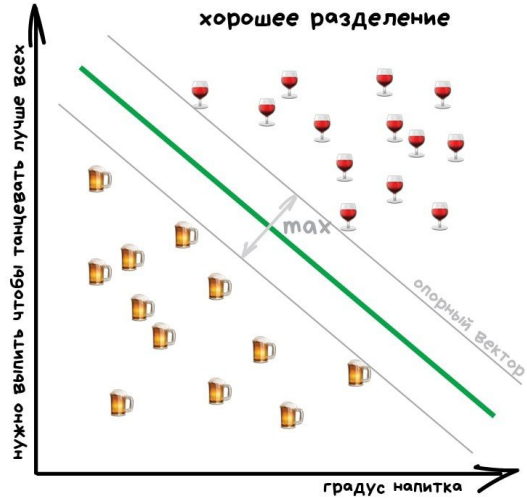
В каком классификаторе
регуляризационный параметр
больше?





Проблема – какой классификатор выбрать?

Разделяем виды алкоголя



SVM – support vector machine (метод опорных векторов)

Хотим максимизировать “зазор” между классами

Это можно сделать, слегка поменяв функцию ошибки, а именно положив её равной:

$$F(M) = \max(0, 1 - M)$$


$$L(w, x, y) = \lambda \|w\|_2^2 + \sum_i \max(0, 1 - y_i \langle w, x_i \rangle)$$

$$\nabla_w L(w, x, y) = 2\lambda w + \sum_i \begin{cases} 0, & 1 - y_i \langle w, x_i \rangle \leq 0 \\ -y_i x_i, & 1 - y_i \langle w, x_i \rangle > 0 \end{cases}$$

Откуда это взялось?

$$\lambda \|w\|_2^2 + \sum_i \max(0, 1 - y_i \langle w, x_i \rangle) \longrightarrow \min_w$$

Первое слагаемое – максимизируем $2/\|w\|$, второе – штрафует за ошибку



Нелинейный SVM

Написанное ранее эквивалентно двойственной задаче оптимизации (через условие Лагранжа):

$$\begin{cases} w = \sum_{i=1}^l \lambda_i y_i x_i; \\ w_0 = \langle w, x_i \rangle - y_i, i : \lambda_i > 0; M_i = 1. \end{cases}$$

Можем получить общее выражение для SVM классификатора

$$a(x) = \text{sign} \left(\sum_{i=1}^l \lambda_i y_i \langle x, x_i \rangle - w_0 \right)$$

А если взять что-то другое как меру “похожести”?



Kernel trick

- Kernel function

$$K(x, x') : X \times X \rightarrow R$$

$\exists \psi : X \rightarrow H : K(x, x') = \langle \psi(x), \psi(x') \rangle$, H - Hilbert space

- Kernel examples


$K(x, x') = \langle x, x' \rangle^2$ - quadratic

$K(x, x') = \langle x, x' \rangle^d$ - polynomial with degree d


$K(x, x') = (\langle x, x' \rangle + 1)^d$ - polynomial with degree $\leq d$

$K(x, x') = \exp(-\gamma \|x - x'\|^2)$ - Radial Basis Functions (RBF) kernel

$$(\langle x, x' \rangle + 1)^d, \quad d=3$$



$$\exp(-\gamma \|x - x'\|^2)$$



H еще называют спрямляющим пространством



PCA – Principal component analysis (метод главных компонент)

Хотим уменьшить размерность задачи без потери информации

$$X_{l,d} \approx U_{l,k} \cdot V_{k,d}^T \quad \|X - UV^T\| \rightarrow \min$$

Сингулярное разложение! (SVD)


$$A = U \Sigma V^T$$

$$A_k = U_k \Sigma_k V_k^T = (U_k \Sigma_k) V_k^T = U_k (\Sigma_k V_k^T)$$

A_k – Приближение матрицы A матрицей ранга k

ХОЧЕТСЯ ВЗЯТЬ





Теорема Экарта-Янга (Eckart-Young) – данное приближение является наилучшим


$$X = U \Sigma V^T$$

orthogonal diagonal: sigmas ~ variance orthogonal


- Consider columns of matrix V new basis vectors: **principal directions**
- Columns of matrix U are called **principal components** of the data
- Singular values are sorted: truncated SVD gives the best projection of dim K



Разделение документов по темам



→
SVD
2. Раскладываем



1. Строим матрицу как часто каждое слово встречается в каждом документе
(чернее - чаще)

3. Получаем наглядные кластера по тематикам
(даже если слова не встречались вместе)

Латентно-семантический Анализ (LSA)

